

线性可分支持向量机

- 数学模型

- $$\begin{cases} w^T x_i + b \geq 0, y_i = +1 \\ w^T x_i + b \leq 0, y_i = -1 \end{cases}$$

- 离超平面最近的样本称为**支持向量**

- 几何间隔

- $$d_{jihe} = \frac{y_i(w * x_i + b_i)}{\|w\|}$$

- 函数间隔

- $$d_{hanshu} = y_i(w * x_i + b_i)$$

- 目标函数

- 文字描述

- **最大化数据集中的最小几何间隔**

- 数学模型

- $$\begin{array}{l} \max \quad d_{jihe}^* = \frac{y_i^*(w * x_i^* + b_i^*)}{\|w\|} \\ \text{st :} \quad d_{jihe} = \frac{y_i(w * x_i + b_i)}{\|w\|} > d_{jihe}^* \quad i = 1, 2, 3, \dots \end{array}$$

- 对于最小**最小**几何间隔的那个点（超平面/支持向量的唯一性），可以变化w,b使得下式等于1，可以简化目标

$$w * x_i^* + b_i^*$$

- 支持向量机基本型

- $$\begin{array}{l} \max \quad d_{jihe}^* = \frac{1}{\|w\|} \quad ==> \quad \min \quad \frac{1}{2} \|w\|^2 \\ \text{st :} \quad d_{jihe} = y_i(w * x_i + b_i) \geq 1 \quad i = 1, 2, 3, \dots \end{array}$$

- 求解二次规划问题

- 由拉格朗日乘子法可得其对偶问题

- $$\begin{array}{l} \max_a \quad \sum_{i=1}^m a_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m a_i a_j y_i y_j x_i^T x_j \quad a \text{ 为每条约束的乘子} \\ \text{st :} \quad \sum_{i=1}^m a_i y_i = 0 \quad ; a > 0 \end{array}$$

- SMO求解对偶问题

- 主要思想是将a中的所有变量中选择两个变量作为分析，其余变量忽略为常熟，求取a的近似解

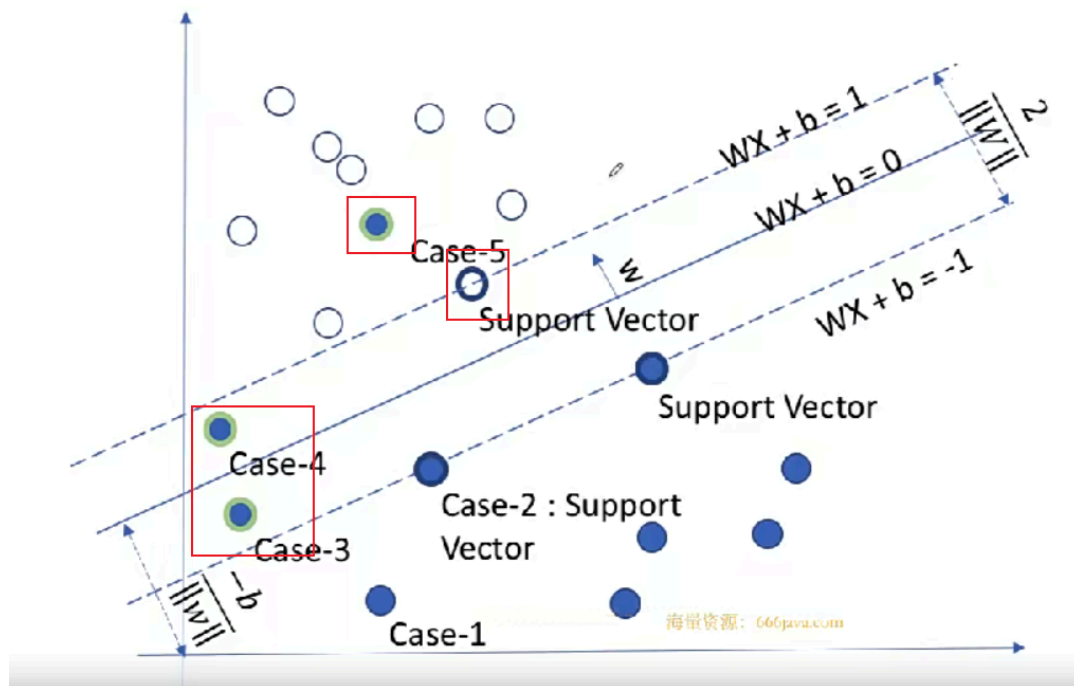
- 不断更新选择的两个变量

- 求出a后可得模型

- $$f(x) = w^T x + b = \sum_{i=1}^m a_i y_i x_i^T x + b$$

带松弛变量的SVM

- 处理有异常值的线性可分svm
- 异常值
 -



- 软间隔主要改变

$$y_i(w * x_i + b_i) \geq 1 - t_i \quad i = 1, 2, 3, \dots$$

- 目标函数

$$\min \quad \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N t_i$$

$$st: y_i(w * x_i + b_i) \geq 1 - t_i, i = 1, 2, 3, \dots, t_i \geq 0$$

- 对偶问题

$$\max_a \quad \sum_{i=1}^m a_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m a_i a_j y_i y_j x_i^T x_j \quad a \text{ 为每条约束的乘子}$$

$$st: \sum_{i=1}^m a_i y_i = 0 \quad ; a > 0; u_i > 0; C - a_i - u_i = 0$$

- \$\$

$y_i y_j$ 表示符号; \quad

$x_i^T x_j$ 表示两个样本的相似度; \quad

$$\text{—合页损失函数—} \min_{w,b} \sum_{i=1}^N [1 - y_i(w * x_i + b)]_+ + \lambda_i \|w\|^2$$

- 可由目标函数推导，并且可以使用梯度方法优化取得w,b

核函数

- 对于在样本维度特征空间中无法线性可分的情况下，可以使用一种映射将原本样本映射到更加高维的空间，寻找一个可分的超平面
- 则对偶问题变为

- $$\frac{\max_a \quad \sum_{i=1}^m a_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m a_i a_j y_i y_j g(x)_i^T g(x)_j}{st : \sum_{i=1}^m a_i y_i = 0 \quad ; a > 0} \quad g \text{为映射}$$
- $$f(x) = w^T x + b = \sum_{i=1}^m a_i y_i g(x)_i^T g(x) + b$$
- 但是因为经过映射后维度可能会很高，使用g(x)计算会使计算大大增加
- $$k(x_i, x_j) = g(x)_i^T g(x)_j$$